

AI & Biologie: Entraînement d'un modèle de classification de famille de protéines via l'architecture transformer & Introduction à la distillation de modèle.

Message au comité de sélection:

Ressources nécessaires :

- COLLAB pour le finetuning du LLM (nécessitera des GPU)
- Notebook
- <https://github.com/Genereux-akotenou/BioAI-and-Distillation> (le code final sera disponible ici)

Divers :

- Nous pourrions envisager de déployer le modèle final via une API si le temps le permet (optionnel).
- Ce projet vise à inspirer sur une direction de recherche en AI très peu explorée ou nouvelle.
- J'ai à ce jour toutes les pièces pour construire le projet (notebook d'introduction à la biologie computationnelle, notebook de classification de protéines, notebook d'introduction à la distillation et des cours de déploiement). Je dois juste structurer le projet s'il est retenu.

IA Biologique

Classification des fonctions de protéines via l'architecture Transformer & Distillation

Efficient Biological AI : des modèles de langage protéiques aux prédicteurs distillés. Un atelier pratique combinant BioIA, représentations et efficacité.

 **Public Cible** : Licence & Master IA

 **Durée** : Modulable

 **Format** : Atelier Pratique & Théorique



Contexte & Motivation



Modèles de Langage Protéiques

Les modèles comme ESM et ProtBERT traitent les séquences d'acides aminés comme un langage, apprenant des représentations riches.



Défis Actuels

Ces modèles sont volumineux (centaines de millions de paramètres) et coûteux en calcul, rendant leur déploiement complexe.




Besoins Réels

L'efficacité est cruciale pour les laboratoires de recherche, les contextes cliniques et les dispositifs embarqués (edge devices).



Ambition du Projet

Créer des prédicteurs fonctionnels précis mais compacts via la distillation de connaissances.



Insight Clé

Transformer l'IA biologique massive en outils pratiques et efficaces.



Introduction



Approche Méthodologique

Combinaison d'embeddings pré-entraînés puissants avec un classifieur optimisé via le transfert d'apprentissage.



Distillation de Connaissances

Transfert de savoir d'un modèle "Enseignant" complexe vers un "Étudiant" léger (utilisant soft targets et température).




Analyse des Compromis

Étude approfondie de la balance entre précision du modèle, nombre de paramètres et latence d'inférence.



Format de l'Atelier

Une approche pratique, reproductible et orientée vers le déploiement réel en environnements contraints.





Objectifs du Projet



Modélisation Langagière

Expliquer comment les séquences protéiques peuvent être traitées comme un langage naturel (tokens, attention).



Embeddings PLM

Exploiter les embeddings vectoriels issus de modèles fondamentaux pré-entraînés comme ESM et ProtBERT.



Classification & Transfert

Construire un classificateur de fonctions protéiques robuste via le transfert d'apprentissage (Transfer Learning).




Distillation de Connaissances

Comprendre la théorie et implémenter un pipeline d'entraînement enseignant-étudiant efficace.



Compression de Modèle

Compresser un modèle de prédiction biologique pour réduire sa taille tout en maintenant des performances compétitives.



Compétence Cible

Maîtriser le pipeline complet : de la représentation biologique théorique à la mise en production efficace.



Contenu du Projet — Modules

MODULE 01



PLMs & Représentations

PRATIQUE & CONCEPTS

- Chargement de dataset de séquences
- Extraction d'embeddings pré-entraînés (ESM/ProtBERT)
- Entraînement d'un classificateur
- Évaluation (Accuracy, F1-score)

Résultat : Un prédicteur fonctionnel opérationnel basé sur un modèle fondamental.

MODULE 02



Distillation de Connaissances

ENSEIGNANT - ÉTUDIANT

- Paradigme Teacher-Student
- Soft targets & Température
- Transfert de "Dark Knowledge"
- Généralisation et compression

Résultat : Compréhension des mécanismes de transfert de connaissances.

MODULE 03



Combinaison & Optimisation

PERFORMANCE VS EFFICACITÉ

- Perte hybride (Cross-entropy + Distillation)
- Comparaison de précision
- Analyse du nombre de paramètres
- Mesure du temps d'inférence

Résultat : Un modèle biologique compressé, rapide et performant.

Pourquoi ce Projet est Valorisant



Pipeline ML Moderne Complet

Démonstration de bout en bout : de l'utilisation de **représentations pré-entraînées** à la classification en aval, jusqu'à la compression du modèle final.



Intersection Interdisciplinaire

Le projet fusionne la **Biologie Computationnelle**, les Modèles Fondamentaux (LLMs) et l'Efficacité des Modèles (Applied ML).



Applications Concrètes

Des compétences directement applicables en médecine, bioinformatique et dans la conception de nouveaux médicaments (**Drug Design**).



Valeur Pédagogique

Les participants expérimentent l'IA biologique de pointe tout en apprenant les contraintes de la **modélisation orientée efficacité**.

Ressources & Outils



FRAMEWORK

PyTorch est recommandé pour sa clarté pédagogique et sa flexibilité.

Recommandé



MODÈLES PRÉ-ENTRAÎNÉS

Utilisation de modèles fondations biologiques majeurs : ESM, ProtBERT ou DNABERT.

HuggingFace



ARCHITECTURES ÉTUDIANTES

Conception de réseaux légers (MLP, CNN simples) pour une inférence rapide.

Lightweight



ENVIRONNEMENT

Accès GPU recommandé pour l'entraînement. Notebooks Jupyter pour la pratique.

Google Colab / Local



PRÉREQUIS

Connaissances de base en Python et introduction aux concepts de Machine Learning.

Niveau Intermédiaire

Merci de votre attention 🙏

Nous avons parcouru le pipeline complet : de l'exploitation de Modèles Fondamentaux massifs à la création de Prédicteurs Distillés agiles, prêts pour le déploiement réel.



Puissance

Utilisation de LLMs biologiques (ESM/ProtBERT) pour une précision maximale.



Distillation

Transfert de connaissances via Teacher-Student et Soft Targets.



Efficacité

Modèles compressés et rapides sans perte majeure de performance.

Place à la pratique : Entraîner & Distiller